

РК N°1 ТМО

Марков И.С. ИУ5Ц-81Б

Вариант N°27

Тема: Технологии разведочного анализа и обработки данных

Задача N°4

Датасет: <https://www.kaggle.com/datasets/johnsmith88/heart-disease-dataset>

```
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns
import numpy as np

# Загрузка данных
df = pd.read_csv('archive/heart.csv')

# Первичный осмотр данных
print("Первые 5 строк данных:")
print(df.head())
print("\nИнформация о данных:")
print(df.info())
```

Первые 5 строк данных:

	age	sex	cp	trestbps	chol	fbs	restecg	thalach	exang	oldpeak
0	52	1	0	125	212	0	1	168	0	1.0
1	53	1	0	140	203	1	0	155	1	3.1
2	70	1	0	145	174	0	1	125	1	2.6
3	61	1	0	148	203	0	1	161	0	0.0
4	62	0	0	138	294	1	1	106	0	1.9

	ca	thal	target
0	2	3	0
1	0	3	0
2	0	3	0
3	1	3	0
4	3	2	0

Информация о данных:

```
<class 'pandas.core.frame.DataFrame'>
```

```

RangeIndex: 1025 entries, 0 to 1024
Data columns (total 14 columns):
#   Column      Non-Null Count  Dtype
---  -
0    age         1025 non-null   int64
1    sex         1025 non-null   int64
2    cp          1025 non-null   int64
3    trestbps    1025 non-null   int64
4    chol        1025 non-null   int64
5    fbs         1025 non-null   int64
6    restecg     1025 non-null   int64
7    thalach     1025 non-null   int64
8    exang       1025 non-null   int64
9    oldpeak     1025 non-null   float64
10   slope       1025 non-null   int64
11   ca          1025 non-null   int64
12   thal        1025 non-null   int64
13   target      1025 non-null   int64
dtypes: float64(1), int64(13)
memory usage: 112.2 KB
None

```

```
# Распределение целевой переменной
```

```

plt.figure(figsize=(8, 6))
sns.countplot(x='target', data=df)
plt.title('Распределение целевой переменной (target)')
plt.xlabel('Наличие сердечного заболевания')
plt.ylabel('Количество пациентов')
plt.show()


```

```
# Статистика по целевой переменной
```

```

target_counts = df['target'].value_counts()
print("\nРаспределение целевой переменной:")
print(target_counts)
print(f"\nПроцент пациентов с заболеванием сердца:
{target_counts[1]/len(df)*100:.1f}%")
print(f"Процент пациентов без заболевания сердца:
{target_counts[0]/len(df)*100:.1f}%")

```



Распределение целевой переменной:

target

1 526

0 499

Name: count, dtype: int64

Процент пациентов с заболеванием сердца: 51.3%

Процент пациентов без заболевания сердца: 48.7%

Выводы:

- 51.3% пациентов имеют сердечное заболевание (target=1)
- 48.7% пациентов не имеют сердечного заболевания (target=0)

Распределение возраста


plt.figure(figsize=(12, 6))

sns.histplot(df['age'], bins=30, kde=True)

plt.title('Распределение возраста пациентов')

```
plt.xlabel('Возраст')
plt.ylabel('Количество пациентов')
plt.show()

# Описательная статистика по возрасту
print("\nОписательная статистика по возрасту:")
print(df['age'].describe())
```



```
Описательная статистика по возрасту:
count      1025.000000
mean        54.434146
std         9.072290
min         29.000000
25%         48.000000
50%         56.000000
75%         61.000000
max         77.000000
Name: age, dtype: float64
```

Возраст пациентов варьируется от 29 до 77 лет


- Средний возраст пациентов - около 54 лет
- Медианное значение возраста - 56 лет
- Распределение возраста имеет небольшой сдвиг в сторону более молодых пациентов

```

# Распределение пола
plt.figure(figsize=(8, 6))
sns.countplot(x='sex', data=df)
plt.title('Распределение пола пациентов (1 = мужчина, 0 = женщина)')
plt.xlabel('Пол')
plt.ylabel('Количество пациентов')
plt.show()

# Статистика по полу
sex_counts = df['sex'].value_counts()
print("\nРаспределение по полу:")
print(sex_counts)
print(f"\nПроцент мужчин: {sex_counts[1]/len(df)*100:.1f}%")
print(f"Процент женщин: {sex_counts[0]/len(df)*100:.1f}%")

```



```

Распределение по полу:
sex
1    713

```

```
0      312
Name: count, dtype: int64
```


```
Процент мужчин: 69.6%
Процент женщин: 30.4%
```

Выводы:

- В наборе данных преобладают мужчины (69.6%)
- Женщины составляют 30.4% от общего числа пациентов
- Такое распределение может повлиять на результаты анализа, так как мужчины и женщины могут иметь разные факторы риска

```
# Корреляционная матрица
plt.figure(figsize=(12, 10))
corr_matrix = df.corr()
sns.heatmap(corr_matrix, annot=True, cmap='coolwarm', fmt='.2f')
plt.title('Корреляционная матрица признаков')
plt.show()

# Наиболее коррелирующие с целевой переменной признаки
print("\nКорреляция признаков с целевой переменной:")
print(corr_matrix['target'].sort_values(ascending=False))
```



Корреляция признаков с целевой переменной:

```
target      1.000000
cp          0.434854
thalach     0.422895
slope       0.345512
restecg     0.134468
fbs         -0.041164
chol        -0.099966
trestbps    -0.138772
age         -0.229324
sex         -0.279501
thal        -0.337838
ca          -0.382085
exang       -0.438029
```

```
oldpeak      -0.438441  
Name: target, dtype: float64
```


Наибольшую положительную корреляцию с целевой переменной имеют:

- cp (тип боли в груди): 0.43
- thalach (максимальная достигнутая ЧСС): 0.42
- slope (наклон сегмента ST при пиковой нагрузке): 0.35

Наибольшую отрицательную корреляцию с целевой переменной имеют:

- exang (стенокардия, вызванная физической нагрузкой): -0.44
- oldpeak (депрессия ST, вызванная физической нагрузкой): -0.43
- ca (количество основных сосудов): -0.39

```
# Диаграмма рассеяния для возраста и холестерина с разделением по полу  
plt.figure(figsize=(10, 8))  
sns.scatterplot(x='age', y='chol', hue='sex', data=df, alpha=0.7)  
plt.title('Диаграмма рассеяния: Возраст vs Холестерин с разделением по  
полу')  
plt.xlabel('Возраст')  
plt.ylabel('Холестерин (мг/дл)')  
plt.legend(title='Пол', labels=['Женщина', 'Мужчина'])  
plt.show()
```



- Наблюдается слабая положительная тенденция: с возрастом уровень холестерина имеет тенденцию к увеличению
- Есть несколько выбросов с очень высоким уровнем холестерина (>400 мг/дл)
- Распределение холестерина у мужчин и женщин визуально не сильно отличается
- Большинство значений холестерина сосредоточены в диапазоне 200-300 мг/дл

```
# Сравнение распределений ключевых показателей для пациентов с  
заболеванием и без  
fig, axes = plt.subplots(2, 2, figsize=(15, 12))  
  
sns.boxplot(x='target', y='age', data=df, ax=axes[0, 0])  
axes[0, 0].set_title('Распределение возраста по наличию заболевания')  
axes[0, 0].set_xticklabels(['Нет', 'Да'])
```

```

sns.boxplot(x='target', y='trestbps', data=df, ax=axes[0, 1])
axes[0, 1].set_title('Распределение давления в покое по наличию
заболевания')
axes[0, 1].set_xticklabels(['Нет', 'Да'])

sns.boxplot(x='target', y='chol', data=df, ax=axes[1, 0])
axes[1, 0].set_title('Распределение холестерина по наличию
заболевания')
axes[1, 0].set_xticklabels(['Нет', 'Да'])

sns.boxplot(x='target', y='thalach', data=df, ax=axes[1, 1])
axes[1, 1].set_title('Распределение максимальной ЧСС по наличию
заболевания')
axes[1, 1].set_xticklabels(['Нет', 'Да'])


plt.tight_layout()
plt.show()

```

```

C:\Users\redmi\AppData\Local\Temp\ipykernel_13888\3166104228.py:6:
UserWarning: set_ticklabels() should only be used with a fixed number
of ticks, i.e. after set_ticks() or using a FixedLocator.
    axes[0, 0].set_xticklabels(['Нет', 'Да'])
C:\Users\redmi\AppData\Local\Temp\ipykernel_13888\3166104228.py:10:
UserWarning: set_ticklabels() should only be used with a fixed number
of ticks, i.e. after set_ticks() or using a FixedLocator.
    axes[0, 1].set_xticklabels(['Нет', 'Да'])
C:\Users\redmi\AppData\Local\Temp\ipykernel_13888\3166104228.py:14:
UserWarning: set_ticklabels() should only be used with a fixed number
of ticks, i.e. after set_ticks() or using a FixedLocator.
    axes[1, 0].set_xticklabels(['Нет', 'Да'])
C:\Users\redmi\AppData\Local\Temp\ipykernel_13888\3166104228.py:18:
UserWarning: set_ticklabels() should only be used with a fixed number
of ticks, i.e. after set_ticks() or using a FixedLocator.
    axes[1, 1].set_xticklabels(['Нет', 'Да'])

```



Выводы:

- Пациенты с заболеваниями сердца в среднем немного старше
- Медианный возраст для больных - около 56 лет, для здоровых - около 52 лет
- У пациентов с заболеваниями сердца давление в покое в среднем немного выше
- Медианное значение для больных - около 130 мм рт.ст., для здоровых - около 125 мм рт.ст.
- Разница в распределении холестерина между группами незначительна
- Обе группы имеют схожие медианные значения около 240-250 мг/дл
- Пациенты с заболеваниями сердца имеют более высокую максимальную ЧСС

- Медианное значение для больных - около 160 уд/мин, для здоровых - около 140 уд/мин