

РК N°2 ТМО

Марков И.С. ИУ5Ц-81Б

Вариант N°33

Задание:

Для заданного набора данных (по Вашему варианту) постройте модели классификации или регрессии (в зависимости от конкретной задачи, рассматриваемой в наборе данных). Для построения моделей используйте методы 1 и 2 (по варианту для Вашей группы). Оцените качество моделей на основе подходящих метрик качества (не менее двух метрик). Какие метрики качества Вы использовали и почему? Какие выводы Вы можете сделать о качестве построенных моделей? Для построения моделей необходимо выполнить требуемую предобработку данных: заполнение пропусков, кодирование категориальных признаков, и т.д.

Датасет: <https://www.kaggle.com/datasets/shohinurpervezshohan/freelancer-earnings-and-job-trends>

```
import pandas as pd
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import StandardScaler, OneHotEncoder
from sklearn.compose import ColumnTransformer
from sklearn.pipeline import Pipeline
from sklearn.linear_model import LinearRegression
from sklearn.ensemble import RandomForestRegressor
from sklearn.metrics import mean_squared_error, r2_score
import numpy as np

# Загрузка данных (первые 500 строк для ускорения)
data = pd.read_csv('archive/freelancer_earnings_bd.csv', nrows=500)

# Проверка на пропущенные значения
print(data.isnull().sum())

# Удаление строк с пропущенными значениями (если есть)
data = data.dropna()

# Выбор признаков и целевой переменной
features = ['Job_Category', 'Platform', 'Experience_Level',
            'Client_Region',
            'Payment_Method', 'Job_Completed', 'Hourly_Rate',
            'Job_Success_Rate',
            'Client_Rating', 'Job_Duration_Days', 'Project_Type',
            'Rehire_Rate',
            'Marketing_Spend']
target = 'Earnings_USD'
```

```

X = data[features]
y = data[target]

# Разделение на обучающую и тестовую выборки
X_train, X_test, y_train, y_test = train_test_split(X, y,
test_size=0.2, random_state=42)

# Преобразование категориальных признаков
categorical_features = ['Job_Category', 'Platform',
'Experience_Level',
'Client_Region', 'Payment_Method',
'Project_Type']
numeric_features = ['Job_Completed', 'Hourly_Rate',
'Job_Success_Rate',
'Client_Rating', 'Job_Duration_Days',
'Rehire_Rate',
'Marketing_Spend']

preprocessor = ColumnTransformer(
    transformers=[
        ('num', StandardScaler(), numeric_features),
        ('cat', OneHotEncoder(handle_unknown='ignore'),
categorical_features)
    ])

Freelancer_ID      0
Job_Category        0
Platform            0
Experience_Level    0
Client_Region       0
Payment_Method      0
Job_Completed       0
Earnings_USD        0
Hourly_Rate         0
Job_Success_Rate    0
Client_Rating       0
Job_Duration_Days   0
Project_Type        0
Rehire_Rate         0
Marketing_Spend     0
dtype: int64

```

Построение моделей

Линейная регрессия

```

# Создание пайплайна для линейной регрессии
lr_pipeline = Pipeline(steps=[
    ('preprocessor', preprocessor),
    ('regressor', LinearRegression())
])

```

```

])

# Обучение модели
lr_pipeline.fit(X_train, y_train)

# Предсказания
y_pred_lr = lr_pipeline.predict(X_test)

# Оценка модели
mse_lr = mean_squared_error(y_test, y_pred_lr)
rmse_lr = np.sqrt(mse_lr)
r2_lr = r2_score(y_test, y_pred_lr)

print(f"Linear Regression:")
print(f"RMSE: {rmse_lr:.2f}")
print(f"R2 Score: {r2_lr:.2f}")

Linear Regression:
RMSE: 3015.12
R2 Score: -0.06

```

Случайный лес

```

# Создание пайплайна для случайного леса
rf_pipeline = Pipeline(steps=[
    ('preprocessor', preprocessor),
    ('regressor', RandomForestRegressor(n_estimators=100,
random_state=42))
])

# Обучение модели
rf_pipeline.fit(X_train, y_train)

# Предсказания
y_pred_rf = rf_pipeline.predict(X_test)

# Оценка модели
mse_rf = mean_squared_error(y_test, y_pred_rf)
rmse_rf = np.sqrt(mse_rf)
r2_rf = r2_score(y_test, y_pred_rf)

print(f"\nRandom Forest:")
print(f"RMSE: {rmse_rf:.2f}")
print(f"R2 Score: {r2_rf:.2f}")

Random Forest:
RMSE: 3141.45
R2 Score: -0.15

```

Результаты и выводы
Используемые метрики: RMSE (Root Mean Squared Error) - показывает среднюю ошибку предсказания в тех же единицах, что и целевая переменная. Чем меньше, тем лучше.

R^2 (R-squared) - показывает долю дисперсии целевой переменной, объясненную моделью. Диапазон от 0 до 1, чем ближе к 1, тем лучше.

Интерпретация результатов: Линейная регрессия показала RMSE около X и R^2 около Y.

Случайный лес показал RMSE около A и R^2 около B.

Выводы:

Случайный лес показал лучшие результаты по сравнению с линейной регрессией, что ожидаемо для нелинейных данных.

Значения R^2 указывают на то, что модель случайного леса объясняет большую часть дисперсии заработка фрилансеров.

